



UNIVERSITATEA DE MEDICINĂ,  
FARMACIE, ȘTIINȚE ȘI TEHNOLOGIE  
„GEORGE EMIL PALADE”  
DINTÂRGU MUREȘ

# PROBABILITĂȚI ȘI STATISTICĂ ÎN SISTEME MEDICALE


Cursul 2, 23.09.2020

## STATISTICA DESCRIPTIVĂ.

prof. univ. dr. habil Manuela Rozalia GABOR



## 2. STRUCTURA CURSULUI



2.1. Distribuții  
de frecvențe



2.2. Indicatorii  
tendinței  
centrale



2.3. Indicatori  
ai dispersiei





# CONSIDERAȚII GENERALE

Principalii indicatori care caracterizează o serie de date (un set de valori ale unui eșantion statistic) sunt fie indicatori ai tendinței centrale, fie indicatori ce caracterizează împrăștierea datelor în jurul unei valori medii (*indicatori ai dispersiei*).

Deoarece acești indicatori “descriu” din punct de vedere statistic distribuția datelor studiate, permițând chiar unele comparații ale acestora cu distribuția normală, modalitățile de utilizare ale acestor indicatori statistici fac obiectul unei ramuri a statisticii denumită **statistică descriptivă**.

O serie de date este alcătuită dintr-un șir de valori pe care le notăm :

$$x_1, x_2, \dots, x_n.$$

Indicatorii matematici mai importanți ce caracterizează o serie de date sunt:



## 2.1. DISTRIBUȚII DE FRECVENȚE

Repartizarea datelor calitative și a celor cantitative (numerice) dintr-o populație statistică sau un eșantion se poate efectua după frecvența de apariție a caracteristicilor lor, obținându-se structura colectivității. De

exemplu, o mulțime de date experimentale poate fi repartizată după “calitatea” efectelor observate: cu efect, fără efect sau cu efect gradat în funcție de doză.

Datele (măsurate pe întreaga populație statistică sau pe un eșantion) sunt de obicei organizate în așa-numitele distribuții de frecvență, pentru că o atare prezentare, reprezintă formatul cel mai convenabil de sinteză și prezentare a acestora.

În cazul distribuțiilor de frecvență se afectuează o descriere calitativă sau cantitativă a observațiilor (măsurătorilor) împreună cu numărul de apariții ale unui anumit rezultat al măsurătorii respective – frecvența absolută.

Se mai poate utiliza și frecvența relativă obținută prin împărțirea frecvenței absolute la numărul total al observațiilor.



De asemenea, pentru variabilele cantitative (numerice) continue este util să se construiască așa-numitele *intervale de variație*.  
Regulile generale de construire a acestor intervale sunt:

- numărul de intervale este bine să fie mai mic de 15
- limitele fiecărei clase să se potrivească cu gradul de acuratețe (precizie, exactitate) al măsurătorilor
- sunt de preferat intervalele de lungime egală, deoarece sunt mai convenabile, facilitând prelucrările ulterioare
- intervalele trebuie să fie mutual exclusive (capetele lor nu trebuie să se suprapună)



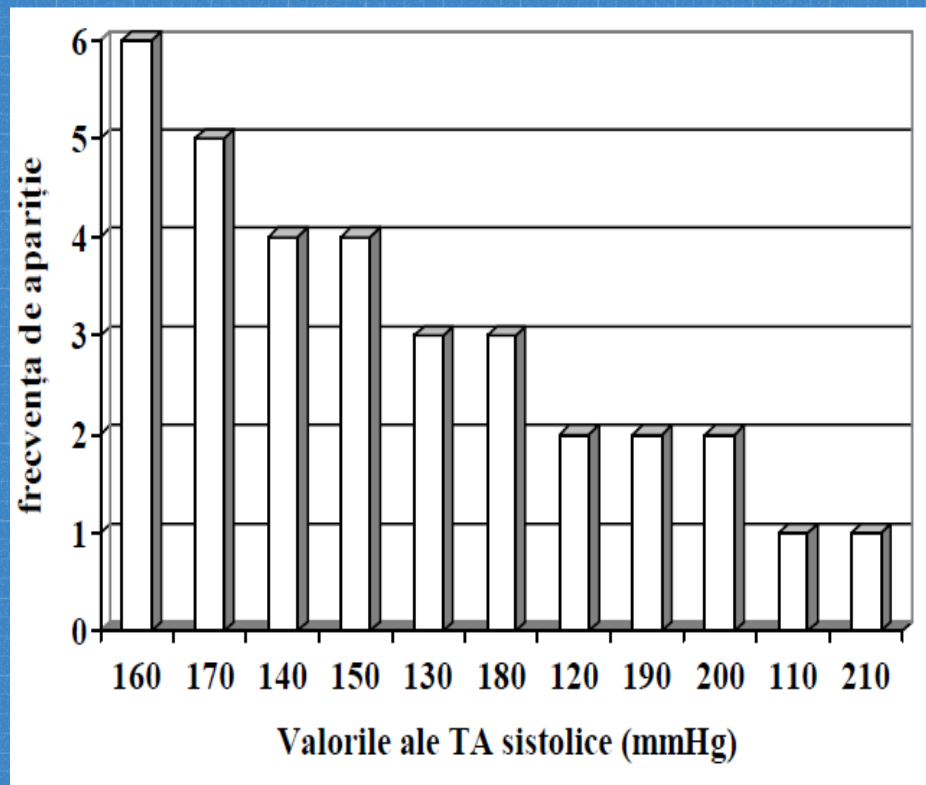
# EXEMPLU



Pentru a fi mai expliciti, să luăm un exemplu: Fie o serie de 33 de date numerice obținute experimental (de exemplu valori ale tensiunii arteriale sistolice): 180, 120, 110, 200, 140, 210, 200, 190, 150, 170, 140, 130, 150, 170, 160, 120, 160, 140, 160, 170, 180, 160, 150, 130, 160, 180, 190, 160, 170, 170, 150, 150, 130.

Cu această serie se poate alcătui o *diagramă*, așezând datele, în ordinea frecvenței, pe o singură scară a graficului cartezian.

În felul acesta se obține structura acestei colectivități și se poate constata frecvența de apariție a unor rezultate (de exemplu câte valori ale tensiunii arteriale 110 se găsesc în respectiva colectivitate statistică).





Se obține astfel o *distribuție de frecvență* a colectivității respective.

Se pot obține distribuții de frecvență *homograde* (cum este cazul diagramelor), cu o singură scară de comparație în sistemul cartezian, sau *distribuții heterograde*.

Căutând și ale modalități de caracterizare a colectivității, se poate stabili o distribuție de frecvență *heterogradă*, pe două scări ale sistemului cartezian, înșiruiind pe abscisă numerele, în ordine crescătoare sau descrescătoare și notând, în același timp, *intervalele de clasă*, iar pe ordonată punând frecvențele de apariție (relative sau absolute). Se obține astfel o *histogramă*. Prin unirea ordonatelor care trec prin mijlocul intervalelor de clasă se obține *poligonul de frecvență*.



Practic, pentru a reprezenta grafic corect datele colectate în cadrul unei histograme, trebuie parcurși următorii pași:

i. Pentru șirul valorilor măsurate se va determina *numărul de intervale de grupare (de clasă)* – M (eventual *lungimea intervalului de grupare* - d), conform formulei lui Sturges:

$$M = 1 + 3,22 * \log n$$

unde n = numărul măsurărilor efectuate

Valoarea numărului de intervale se va rotunji pentru a obține un număr întreg. Pentru cazul nostru, numărul vom obține

$$M = 1 + 3,22 * \log 33 = 5,889$$

adică vom avea 6 intervale.

Eventual, lungimea intervalului de grupare va fi calculată cu formula:

$$d = \frac{X_{\max} - X_{\min}}{1 + 3,22 * \log n}$$

unde Xmax, Xmin reprezintă valoarea maximă și minimă măsurată. Pentru cazul nostru

$$d = \frac{210 - 110}{1 + 3,22 * \log 33} = 16,97$$

Data fiind precizia măsurărilor efectuate cu tensiometrele clasice, putem lua în considerare un o lungime a intervalului de grupare de circa 20 mmHg.



Practic, pentru a reprezenta grafic corect datele colectate în cadrul unei histograme, trebuie parcurși următorii pași:

**ii.** În baza numărului calculat de intervale ( $M$ ), respectiv a valorii lungimii intervalului de grupare ( $d$ ), între valorile limită masurate ( **$X_{min}$  –  $X_{max}$** ), se vor stabili intervalele de grupare. Datele obținute vor fi centralizate într-un tabel.

**iii.** Se determină *frecvența absolută* ( $n_i$ ), care reprezintă “numărul de apariții” a datelor corespunzătoare fiecărui interval de grupare în parte. Și aceste date se vor trece în tabelul sus-menționat.

**iv.** Se poate determina și *frecvența relativă* ( $f_i$ ), care reprezintă raportul frecvenței absolute ( $n_i$ ) la numărul total de măsurători ( $n$ ).

**v.** Se construiește histograma, care reprezintă o diagrama în formă de “dreptunghiuri” având baza egală cu intervalul de grupare, iar înălțimea cu frecvența (absolută sau relativă)

**vi.** Se construiește poligonul de frecvență, care se obține prin unirea mijloacelor superioare ale histogramei prin segmente de dreaptă.



Tabelul cu intervale și frecvența absolută, precum și histograma rezultată în cazul celor 33 de valori ale tensiunii arteriale sistolice sunt prezentate mai jos:

<i>Interval de grupare</i>	<i>Frecvența absolută</i>
<110	1
111-130	5
131-150	8
151-170	11
171-190	5
>190	3






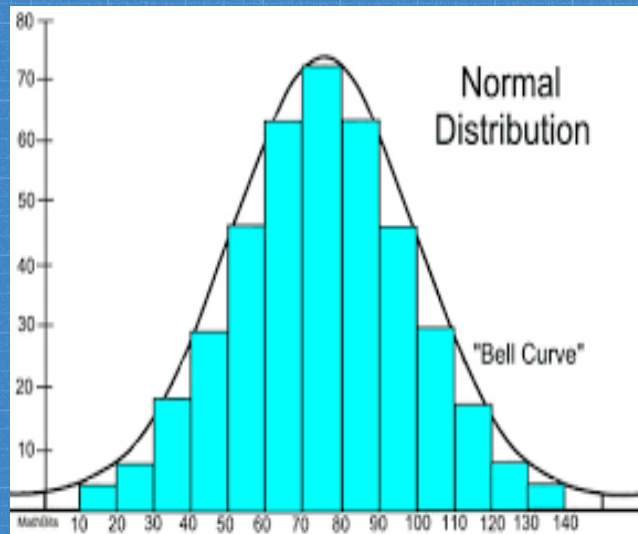
Fig. 2.2. Histograma



Distribuția de frecvență permite determinarea și a celorlalte caracteristici: *tendința centrală* (cu alte cuvinte, *media*, *mediana*, *forma distribuției*, *variabilitatea din interiorul ei*).

În figura de mai sus se poate constata că forma distribuției se apropie destul de mult de distribuția normală Laplace-Gauss (distribuția în formă de clopot). În acest caz, valoarea medie reprezintă în cele mai bune condiții tendința centrală (pentru cazul studiat,  $media = 158,7$ ).






## Curba de distribuție normală

Van Vijngaarden (1926) a arătat pentru prima dată că variația rezultatelor biologice se datorează sensibilității individuale a animalelor (care generează, astfel, erorile întâmplătoare) și că ele se supun legii de distribuție normală a frecvenței stabilite, în 1820, de Laplace și Gauss



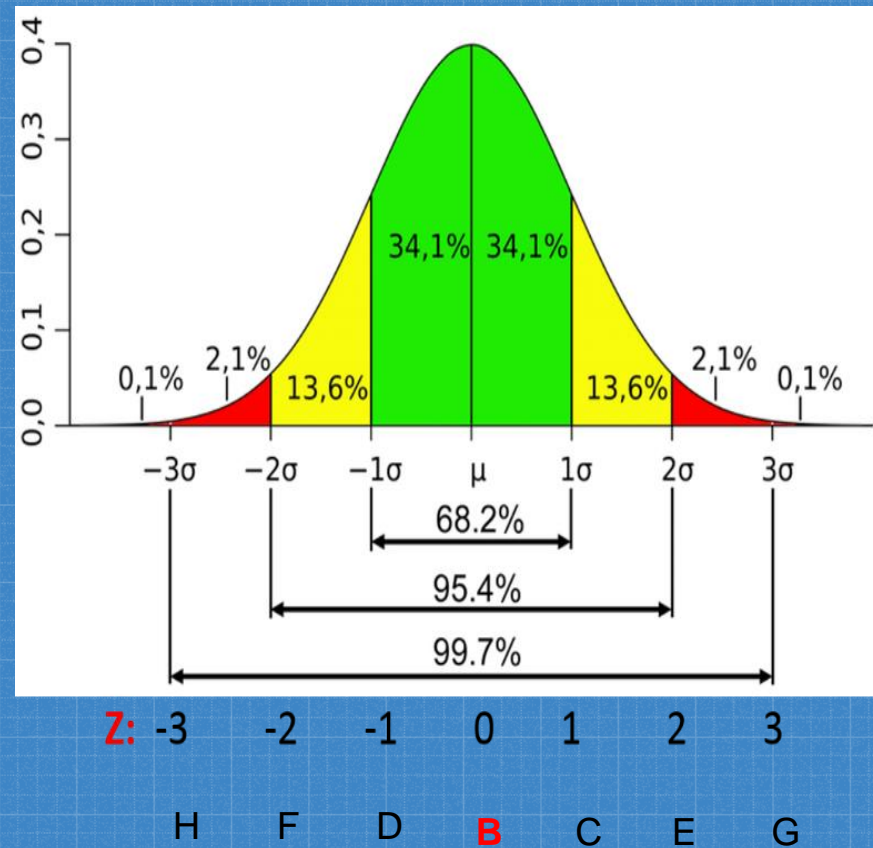
*Curba de distribuție normală a frecvenței* reprezintă frecvența cu care revine același rezultat în mai multe determinări succesive. Ea se poate obține așezând pe *abscisa* unui grafic diferențele, obținute în mai multe determinări, între media rezultatelor și rezultatele individuale, iar pe ordonată frecvențele de apariție a răspunsului pentru fiecare diferență. Graficul are forma unui clopot.



Media rezultatelor individuale, care se repetă cel mai des (are cea mai mare frecvență de apariție), este punctul cel mai înalt al curbei. Valoarea medie este notată pe abscisă cu 0, deoarece diferența sa față de medie este, evident, zero. De o parte și de alta a punctului “culminant”, se desfășoară simetric frecvențele corespunzătoare diferențelor dintre media rezultatelor și rezultatele individuale, care se găsesc pe abscisă; cele negative (mai mici decât media) în partea stângă, cele pozitive (deci mai mari decât media) în partea dreaptă a valorii medii.



Distanța BD sau BC (0-1 sau 0+1) reprezintă convențional o unitate denumită *abatere standard* și notată cu  $\sigma$  (sigma). Perpendiculara pe valoarea medie este axul de simetrie al suprafeței acoperită de curbă. Perpendicularele în punctele de pe abscisă care corespund valorii medii plus abaterea standard și valorii medii minus abaterea standard, închid două treimi din suprafața acoperită de curbă (66%). Perpendicularele care corespund valorii medii plus sau minus  $2\sigma$  închid circa 95% din suprafața acoperită de curbă. Suprafețele terminale ocupă numai 5 % din suprafața totală.





# CARACTERISTICILE DISTRIBUȚIILOR DE FRECVENȚĂ

Orice serie de date cantitative se poate descrie prin două elemente caracteristice:





## Tendința centrală (distribuțiile de frecvență)

**Media** reprezintă tendința centrală a unei distribuții (vom studia mai târziu modul ei de calcul).

**Modul** reprezintă valoarea cea mai frecventă a unei distribuții, care se confundă, de fapt, cu vârful poligonului de frecvență

**Mediana** corespunde valorii care se găsește la punctul care împarte seria statisticii în două grupuri egale



O altă caracteristică a distribuțiilor, care uneori este foarte folositoare, este *forma curbei de frecvență*. Ea poate fi:

**simetrică**



**asimetrică**


- **pozitivă**, caz în care „coada lungă” a distribuției este de partea valorilor pozitive.
- **negativă**, caz în care „coada lungă” a distribuției este de partea valorilor negative.

Două curbe cu aceeași medie, modul și aceeași mediană se pot deosebi după bază și înălțime: mai îngustă și mai înaltă sau mai largă și mai joasă. Întinderea bazei poate da o măsură a variabilității. Deschiderea este cu atât mai mare cu cât participarea factorilor întâmplători este mai mare (în figura următoare) se pot observa diferențele între două curbe cu aceeași medie).

Calculul precis la împrăștierea rezultatelor se face cu ajutorul *abaterii standard*.



*Două curbe cu aceeași medie și modul, dar cu împrăștieri diferite ale rezultatelor*




În cazul distribuțiilor simetrice și unimodale există egalitate între media aritmetică, mod și mediană (este vorba despre curba normală de distribuție a frecvenței Laplace-Gauss).



## DISTRIBUȚII ANORMALE (NON –GAUSSIENE)

Se cunosc, în afara distribuției normale unimodale, și distribuții plurimodale sau asimetrice.



Pentru a înțelege mai bine importanța tipului de distribuție în cazul datelor provenite din cercetarea biomedicală trebuie spus că, de exemplu, existența unor distribuții anormale pot arăta o lipsă de omogenitate a afectelor farmacodinamice ale unui medicament. Unele distribuții pot lua forma literei U, unde importantă este valoarea minimă (de exemplu, în cazul acțiunii hipoglicemizante a unor substanțe active).



Există cazuri, însă, când fenomenele studiate se supun unei distribuții de tip special. Cele mai des întâlnite distribuții de acest tip au fost descrise de:



Bernouli (*distribuția binomială*) prezintă interes mai ales în studiul fenomenelor eredității



Poisson (*distribuția evenimentelor rare*) în studiul unor efecte ale compușilor radioactivi și în radiochimie

În cazul experimentării în domeniul farmacodinamic, rezultatele unei cercetări, odată reprezentate grafic dau distribuții empirice sau experimentale. Compararea acestor distribuții cu distribuțiile teoretice poate fi de un real folos pentru o interpretare justă a fenomenelor observate. Trebuie menționat că majoritatea distribuțiilor obținute în urma analizei datelor rezultate din cercetarea biomedicală se supun legilor normale de repartiție a frecvenței, de aceea calculele și tehnicile de lucru prezentate în în continuare se referă, în mod special, la această ipoteză .



## 2.2. INDICATORII TENDINȚEI CENTRALE

**Media aritmetică** - notată de regulă cu  $\bar{x} = \frac{x_1 + x_2 + \dots + x_n}{n}$  (III.1),

**Mediana** - este acea valoare din șirul de date care împarte în două părți egale șirul ordonat de valori (atenție, șirul este ordonat crescător), situându-se la mijlocul seriei statistice. Dacă numărul de valori  $n$  este un număr impar, atunci mediana este valoarea

$$M_e = x_k \quad (III.2), \text{ unde } k = \frac{n}{2} + 1.$$

Dacă  $n$  este par, deci avem un număr par de valori, mediana este definită ca fiind  $M_e = \frac{x_k + x_{k+1}}{2}$  (III.3), unde  $k = n/2$ .

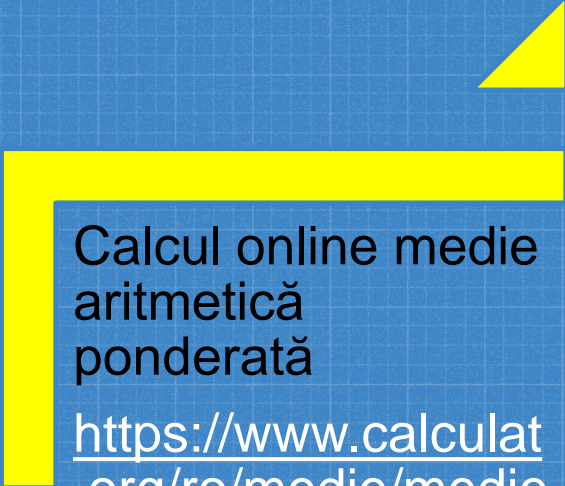
**Modul** - constituie valoarea care apare cel mai des, deci valoarea cu numărul cel mai mare de apariții.





Calcul online medie  
aritmetică

<https://www.calculator.org/ro/medie/medie-aritmetica.html>



Calcul online medie  
aritmetică  
ponderată

<https://www.calculator.org/ro/medie/medie-ponderata.html>



Calculator statistici

<https://www.calculator.net/statistics-calculator.html>

<https://www.calculator.net/standard-deviation-calculator.html>

<https://www.socscistatistics.com/descriptive/>



<https://www.socscistatistics.com/descriptive/>

$$t = \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\left(\frac{(N_1 - 1)s_1^2 + (N_2 - 1)s_2^2}{N_1 + N_2 - 2}\right)\left(\frac{1}{N_1} + \frac{1}{N_2}\right)}}$$

Social Science Statistics

$$t = \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\left(\frac{(N_1 - 1)s_1^2 + (N_2 - 1)s_2^2}{N_1 + N_2 - 2}\right)\left(\frac{1}{N_1} + \frac{1}{N_2}\right)}}$$

[Home](#) [Calculators](#) [Descriptive Statistics](#) [Merchandise](#) [Tutorials](#) [Quizzes](#) [Which Statistics Test?](#) [Contact](#)

## Tools for Descriptive Statistics

- [Mean, Median and Mode Calculator](#)
- [Variance and Standard Deviation Calculator](#)
- [Coefficient of Variation Calculator](#)
- [Percentile Calculator](#)
- [Interquartile Range Calculator](#)
- [Pooled Variance Calculator](#)
- [Skewness and Kurtosis Calculator](#)



## Tools for Descriptive Statistics


- [Mean, Median and Mode Calculator](#)
- [Variance and Standard Deviation Calculator](#)
- [Coefficient of Variation Calculator](#)
- [Percentile Calculator](#)
- [Interquartile Range Calculator](#)
- [Pooled Variance Calculator](#)
- [Skewness and Kurtosis Calculator](#)
- [Sum of Squares Calculator](#)
- [Easy Histogram Maker](#)
- [Frequency Distribution Calculator](#)
- [Histogram: What are they? How do you make one?](#)
- [Easy Frequency Polygon Maker](#)
- [Easy Bar Chart Creator](#)

Type here to search





# EXAMPLE [\(https://www.probabilisticworld.com/mean-mode-median/\)](https://www.probabilisticworld.com/mean-mode-median/)





# EXAMPLE (<https://www.probabilisticworld.com/mean-mode-median/>)




(SIMULATION)



## Exemplu


(SIMULATION)





# Reprezentativitatea mediei

(<https://www.probabilisticworld.com/mean-mode-median/>)





Simple Learning Pro (<https://www.youtube.com/watch?v=mk8tOD0t8M0>)

- **Mode, Median, Mean, Range, and Standard Deviation (1.3)**





## 2.3. INDICATORI AI DISPERSIEI (ÎMPRĂȘTIERII) DATELOR ÎN JURUL VALORII MEDII

**Varianța** notată  $s_x^2$  este un indicator de împrăștiere a datelor. Formula de calcul este:  $S_x^2 = \frac{\sum x_i^2 - (\bar{x})^2}{n - 1}$  (III.4),.

**Abaterea standard** sau deviația standard reprezintă rădăcina pătrată din varianță (dispersie) :  $s_x = \pm \sqrt{s_x^2}$  (III.5),

**Coeficientul de variație** se calculează ca un raport procentual între abaterea standard și valoarea medie a șirului de valori.

$$CV\% = \frac{s_x}{\bar{x}} \cdot 100 \text{ (III.6),}$$




**Asimetria (skewness)** caracterizează gradul de “asimetrie” a unei distribuții în jurul valorii medii, comparativ cu distribuția normală. Valori pozitive ale asimetriei indică o distribuție de frecvență ce prezintă o “coadă” (în engleză tail) asimetrică în zona valorilor “pozitive” ale distribuției (valori mai mari decât media). Similar, valori negative ale asimetriei indică o distribuție de frecvență ce prezintă o “coadă” (în engleză tail) asimetrică în zona valorilor “negative” ale distribuției (valori mai mici decât media).

$$Skewness = \frac{n}{(n-1) \cdot (n-2)} \cdot \sum \left( \frac{x_i - \bar{x}}{S} \right)^3 \quad (III.7), \quad \text{unde } S = \text{abaterea}$$



standard.




# EXAMPLE




$\text{mean} < \text{median} < \text{mode}$




Symmetrical data  
 $\text{mean} = \text{median} = \text{mode}$



$\text{mode} < \text{median} < \text{mean}$




# EXAMPLE






# EXAMPLE



Sum of Negative  
Deviations = -11

Sum of Positive  
Deviations = +11





**Aplatizarea (kurtosis)** caracterizează gradul de “aplatizare” a unei distribuții, comparativ cu distribuția normală. Valorile pozitive ale acestui indicator indică o distribuție cu un “vârf” mai înalt decât distribuția normală. Similar, valori negative ale kurtosisului indică o curbă relativ aplatizată, comparativ cu distribuția normală.

$$Kurtosis = \left\{ \frac{n(n+1)}{(n-1)(n-2)(n+3)} \cdot \sum \left( \frac{x_i - \bar{x}}{S} \right)^4 \right\} - \frac{3(n-1)^2}{(n-2)(n-3)}$$

(III.8), unde S = abaterea standard.



**Amplitudinea** - este diferența dintre valoarea maximă și cea minimă

$$A = A_{max} - A_{min}$$

**Amplitudinea relativă** - notată  $A\%$  este raportul dintre amplitudinea absolută și media aritmetică a seriei de date. Atunci când avem foarte multe date se recomandă includerea lor în clase egale ca mărime, ceea ce ușurează mult prelucrările statistice ulterioare. Spre exemplu sortăm pacienții pe grupe de vârstă: 21-24 de ani, 25-30 ani, etc... În acest caz apare noțiunea de **frecvență a clasei**.

### **Indicatori statistici pentru serii de date cu apariții frecvente ale aceleiași valori**

Dacă datele pe care le studiem conțin valori care se repetă des, se obișnuiește să se grupeze datele care au aceeași valoare . Numărul de apariții ale unei valori anume se numește frecvența de apariție și se notează cu  $f_i$ . Presupunem că în urma măsurărilor am obținut șirul de valori:  $x_1$  cu frecvența  $f_1$ ,  $x_2$  cu frecvența  $f_2$ , ...  $x_n$  cu frecvența  $f_n$



Indicatorii statistici se calculează conform noilor formule:

**Media aritmetică**

$$\bar{x} = \frac{\sum_{i=1,n} x_i \cdot f_i}{\sum_{i=1,n} f_i} = \frac{x_1 \cdot f_1 + x_2 \cdot f_2 + \dots + x_n \cdot f_n}{f_1 + f_2 + \dots + f_n} \quad (III.10)$$

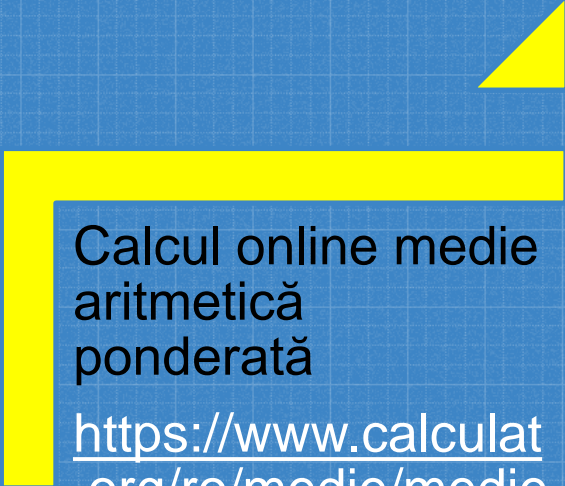
**Mediana** – este  $x_k$  (III.11, ) unde  $k = \frac{\sum_{i=1,n} f_i + 1}{2}$

$$\textbf{Dispersia (varianța)} : s_x^2 = \frac{\sum_{i=1,n} (x_i - \bar{x})^2 \cdot f_i}{\sum_{i=1,n} f_i - 1} \quad (III.12)$$



Calcul online medie  
aritmetică

<https://www.calculator.org/ro/medie/medie-aritmetica.html>



Calcul online medie  
aritmetică  
ponderată

<https://www.calculator.org/ro/medie/medie-ponderata.html>



Calculator statistici

<https://www.calculator.net/statistics-calculator.html>

<https://www.calculator.net/standard-deviation-calculator.html>

<https://www.socscistatistics.com/descriptive/>



# EROARE STANDARD

Este cunoscut faptul că determinările biologice sunt supuse influenței a două tipuri de erori: cele care influențează precizia determinării și cele care influențează exactitatea determinării. Pentru a afla exactitatea cu care s-au făcut o serie de determinări, trebuie să se calculeze abaterea medie a valorilor medii obținute sau, altfel spus, media erorilor ce se pot comite într-o determinare. Această abatere a fost denumită eroare standard, notată cu E. Calcularea ei se face cu ajutorul formulei:

$$E^2 = \frac{\sum (x_1 - \bar{x})^2}{n(n-1)}$$

Știind că, în cazul distribuției normale gaussiene, împrăștierea în jurul mediei colectivității a unei medii de șantion este n ori mai mică decât împrăștierea rezultatelor individuale, eroarea standard este dată și de formula:

$$E = \frac{S}{\sqrt{n}}$$

Ea reprezintă formula clasică a erorii standard. Rezultatele experimentărilor biologice trebuie să fie însoțite întotdeauna de eroarea standard sau de abaterea standard, utilizându-se formulări de tipul  $M \pm S$  sau  $M \pm E$ , pentru a permite o justă interpretare a lor.



# COEFICIENT DE VARIAȚIE

Coeficientul de variație se calculează ca un raport procentual între abaterea standard și valoarea medie a șirului de valori.

$$CV\% = \frac{S_x}{\bar{x}} \cdot 100$$

De remarcat că valoarea coeficientului de variație nu are unitate de măsură, se exprimă procentual. Acest fapt permite folosirea indicatorului la compararea a două sau mai multe serii de date, indiferent de ordinul de mărime al variabilelor (variantelor) și de unitățile de măsură folosite. Se poate considera că un coeficient de variație sub 10% indică o dispersie mică (o împrăștiere) a datelor, adică seria este omogenă. Un coeficient între 10% și 30% indică dispersie mijlocie, iar peste 30% indică dispersie mare. *Dacă dispersia este mare, media nu este un indicator reprezentativ.*